

CardioCare

기말 프로젝트 보고서

End-to-End ML System for Heart Disease Prediction

작성자: 천잉지에

학번: 202324037

과목: 기계학습 · CardioCare 기말 프로젝트

윤리 선언

GitHub: <https://github.com/touyoupo/cardiocare>

본 시스템은 심장 전문의의 의사결정을 보조하는 도구이며, 독립적인 진단 자격이 없습니다. 모든 최종

의료 결정은 면허를 가진 의사가 내려야 합니다. 모델은 편향이 있을 수 있으며, 전문 의료 진단을

대체할 수 없습니다.

1-2. 문제 정의 · EDA · 전처리

1.1 문제 정의 및 데이터셋

CardioCare는 임상 특성으로 심장병 위험을 예측하여 의사 판단을 보조합니다

(inform, not decide). UCI Cleveland 303행, seed=42.

위음성(FN)이 위양성보다 임상적으로 더 위험하여 recall 중심 평가.

1.2 윤리 선언

본 시스템은 심장 전문의의 의사결정을 보조하는 도구이며, 독립적인 진단 자격이 없습니다. 모든

최종 의료 결정은 면허를 가진 의사가 내려야 합니다. 모델은 편향이 있을 수 있으며, 전문

의료 진단을 대체할 수 없습니다.

2.1 EDA 및 전처리


불균형 클래스, '?' 결측, chol/trestbps/oldpeak 이상치 확인.

중앙값/최빈값 대체, IQR 클리핑, train_test_split 후 fit(누수 방지).

그림 1-2: notebook EDA — 클래스 분포 및 연속 특성 박스플롯.


1-2. EDA

그림 1. 타겟 클래스 분포



질병(1) 비율이 건강(0)보다 높아 불균형 확인.

그림 2. 연속 특성 박스플롯



4. 모델 비교 및 선정

세 가지 모델 계열을 MLflow로 기록하고 재현율(Recall) 기준으로 최종 모델을 선정했습니다.

Model	Accuracy	Recall	Precision	F1	AUC	Bal.Acc
logistic_regression	0.869	0.929	0.812	0.867	0.935	0.873
svc	0.820	0.893	0.758	0.820	0.897	0.825
random_forest	0.869	0.893	0.833	0.862	0.936	0.871

최종 모델: Logistic Regression (Recall 최고, 0.929)


홀드아웃: accuracy=0.869, auc=0.935, f1=0.867

선정 근거: 위음성(FN) 위험을 줄이기 위해 재현율(Recall) 최대화.

MLflow 3개 모델 계열 실험 기록 — 그림 7 참조.


3-4. 모델 평가

그림 3. 혼동 행렬



홀드아웃 테스트셋 혼동 행렬.

그림 4. 특성 중요도



5. 테스트 및 MLOps 메타데이터

5.1 단위 테스트

tests/test_pipeline.py — (1) 예측 shape (2) 확률 [0,1] 및 합=1 (3) 임상 범위 검증 (4) seed=42 결정론 재현.

5.2 Docker 및 CI

Dockerfile(python:3.10-slim) + src/inference.py 배치

추론. GitHub Actions: dvc repro 및 단위 테스트 자동 실행.

저장소: <https://github.com/touyoupo/cardiocare>

5.3 Feature Store


등록 특성: chol. 콜레스테롤(chol)은 심혈관 위험의 핵심 연속 지표로, 전처리(IQR 클리핑·표준화) 후 재사용 가능한 표준 특성입니다.

5.4 Model Registry

메타데이터 필드: recall_on_holdout = 0.929. 위음성(FN) 위험을 줄이기 위해 홀드아웃 재현율을 모델 승격·롤백의 1차 기준으로 등록합니다.


5-6. 드리프트 모니터링

그림 5. KS 드리프트 (chol)




훈련 분포 vs 드리프트 테스트 분포; $p < 0.05$ 플래그.

그림 6. 모니터링 시계열




7-8. MLflow · MLOps

그림 7. MLflow 실험 기록



3개 모델 계열(logistic_regression, svc, random_forest) 실험 비교.

그림 8. MLOps 페루프



Commit → CI → CD → CM → CT → Review → Model Update.

6-7. 드리프트 · DVC · 서빙

6. 드리프트 감지 및 재학습

KS 검정 기준: 훈련 분포 vs 드리프트 분포. 플래그 특성: chol, thalach, oldpeak.

성능 변화 — recall 0.929 → 0.750, balanced accuracy

0.873 → 0.693.

재학습 정책: KS p-value < 0.05 이고 recall 5%p 이상 하락 시 트리거.

폭주 피드백 루프 방지를 위해 자동 재배포 금지, Human-in-the-loop(심장 전문의 승인) 후에만 모델 갱신.

7. 서빙 선택 · DVC · 경량화

서빙: Model-as-a-Service(MaaS) 채택. On-Device는 PHI가 단말에

분산·모델 업데이트가 느려 임상 환경에 부적합.

MaaS 정당화 — (1) 지연: 배치 추론·비용급 스크리닝에 충분 (2) PHI: 병원 서버

내 처리·접근 통제 (3) 업데이트: 중앙 Registry에서 주기적 재학습·롤백.

DVC: dvc.yaml 3단계, dvc.lock, params.yaml(seed=42).

경량화: SelectFromModel:joblib, 임상 범위 검증.

8. 한계 · 윤리 · 부록

8.1 한계 및 향후 과제

소규모 단일 기관 데이터, 편향 가능, SHAP/외부 검증 필요.

8.2 윤리 선언 (마무리)

본 시스템은 심장 전문의의 의사결정을 보조하는 도구이며, 독립적인 진단 자격이 없습니다. 모든 최종 의료 결정은 면허를 가진 의사가 내려야 합니다. 모델은 편향이 있을 수 있으며, 전문 의료 진단을 대체할 수 없습니다.

부록: AI 도구 사용 공개

본 프로젝트는 ChatGPT를 코드 템플릿 작성 및 디버깅에 사용했으며, 모든 핵심 로직과 실험 결과는 본인이 독립적으로 완성했습니다. scikit-learn 공식 문서 및 UCI 데이터셋 페이지를 참고했으며, 관련 소스 파일에 출처 링크를 주석으로 표기했습니다.